Exemple Complet de Négociation via Transformer

Cas d'usage : Cours Machine Learning (TP)

Scénario

Le cours de **Machine Learning (TP)** doit être planifié avec les contraintes suivantes : type TP (nécessite un laboratoire) et une durée de 2 heures. Quatre créneaux sont disponibles : **S1** (Lundi 8h), **S2** (Lundi 14h), **S3** (Mardi 10h) et **S4** (Mercredi 16h). Trois agents participent à la négociation : le représentant des étudiants, l'enseignant et le gestionnaire des salles.

Étape 1 — Propositions initiales des agents

Chaque agent évalue les créneaux disponibles selon ses contraintes et attribue un score de préférence entre 0 et 1 :

Agent	S1 (Lun 8h)	S2 (Lun 14h)	S3 (Mar 10h)	S4 (Mer 16h)	Raison
Étudiants	0.2	**0.9**	0.6	0.1	Évitent
Enseignant	0.3	0.5	**0.85**	0.4	Disponi
Gestionnaire salles	0.2	0.1	**1.0**	0.7	Labo lib

Table 1 – Scores de préférence des agents par créneau

On observe un **conflit** : les étudiants préfèrent S2 (0.9) tandis que l'enseignant et le gestionnaire des salles préfèrent S3 (0.85 et 1.0 respectivement).

Étape 2 — Construction du Token du cours

Dans le SchedulingTransformer, chaque cours est représenté par un **token** qui encapsule l'ensemble des informations de négociation. Le token est construit en concaténant les métadonnées du cours avec les scores des trois agents :

```
Vecteur brut du token :

[ course_id=7,      ← identifiant du cours
type=2,          ← encodage du type TP
0.2, 0.9, 0.6, 0.1,  ← scores étudiant (S1..S4)
0.3, 0.5, 0.85, 0.4, ← scores enseignant (S1..S4)
0.2, 0.1, 1.0, 0.7  ]← scores salle (S1..S4)
```

Ce vecteur brut (14 dimensions) est ensuite transformé en un **embedding dense de 256 dimensions** via une projection apprise. C'est ce vecteur enrichi qui circule à travers les couches du Transformer : chaque token représente ainsi une "table de négociation compressée" contenant simultanément les avis des trois agents.

Étape 3 — Mécanisme d'attention (Réunion interne)

Le mécanisme d'attention multi-têtes analyse les différentes dimensions du token en parallèle, chaque tête se spécialisant sur un aspect de la négociation :

Tête	Spécialisation	Focus principal
Head 1	Confort étudiant	Analyse scores étudiants, évitement créneaux matinaux
Head 2	Disponibilité enseignant	Vérification des contraintes horaires de l'enseignant
Head 3	Contraintes salle	Disponibilité du laboratoire, capacité, équipements
Head 4	Type de cours (TP)	Renforcement des contraintes liées au type TP

Table 2 – Spécialisation des têtes d'attention

Étapes 4-6 — Tours de négociation (Layers 1 et 2)

Le traitement s'effectue en deux couches successives, chacune représentant un tour de négociation :

Layer 1 — Détection du conflit : La première couche fusionne les scores des agents. S2 obtient un bon score étudiant (0.9) mais un score salle nul (0.1 car labo occupé). S3 obtient un bon score enseignant (0.85) et salle (1.0) mais un score étudiant modéré (0.6). Le conflit S2 vs S3 est détecté, le token est en état d'hésitation.

Layer 2 — Résolution par pondération : Le modèle a appris que pour un cours de type TP, la **contrainte de disponibilité du laboratoire est une contrainte forte** (inviolable). Le poids accordé aux scores du gestionnaire de salles est augmenté. Le token recalcule son état interne :

$$\text{importance(salle)} \uparrow \quad \Rightarrow \quad \text{importance(étudiant)} \downarrow_{\text{légèrement}} \tag{1}$$

Le créneau dominant devient alors **S3 (Mardi 10h)**, car il satisfait la contrainte forte (labo disponible) et maximise la satisfaction globale.

Étape 7 — Décision finale du token

Après traitement par les couches d'attention, le token produit une distribution de probabilités sur les créneaux via une fonction **Softmax** :

$$P(\text{créneau}) = \text{Softmax(logits)} = \begin{pmatrix} S1 \\ S2 \\ S3 \\ S4 \end{pmatrix} = \begin{pmatrix} 5\% \\ 22\% \\ \mathbf{61}\% \\ 12\% \end{pmatrix} \tag{2}$$

Créneau	Probabilité	Satisfaction globale	Décision
S1 (Lun 8h)	5%	Faible	Écarté
S2 (Lun 14h)	22%	Moyenne (labo indisponible)	Écarté
successgreen!20 **S3 (Mar 10h)**	**61%**	**Élevée (compromis optimal)**	**Choisi**
S4 (Mer 16h)	12%	Modérée	Écarté

Table 3 – Distribution de probabilités finale et décision

Résultat final :

Machine Learning (TP) → Mardi 10h

Score de satisfaction global : 78%

Étudiants : 60% Enseignant : 85% Salle : 100%

Synthèse — Interprétation conceptuelle

Dans notre SchedulingTransformer, chaque cours est représenté par un **token** contenant les préférences des étudiants, de l'enseignant et les contraintes de salle. Ces informations sont encodées sous forme de vecteur (embedding). Les couches d'attention du Transformer pondèrent ces préférences comme lors d'une négociation multi-agents : chaque tête d'attention analyse un angle différent (confort étudiant, disponibilité enseignant, contraintes salle, type de cours), tandis que chaque couche représente un tour de négociation supplémentaire. Après plusieurs tours de traitement, le token converge vers le créneau **S3 (Mardi 10h)**, qui constitue le compromis optimal satisfaisant les contraintes fortes (disponibilité du laboratoire) tout en maximisant la satisfaction globale des trois parties prenantes.