Agents et Intelligence Artificielle - Le coeur battant de l'IA

Yu LI

2025-2026

Cours 5 : LLM — Large Language Model

Un LLM (Large Language Model) est un type d'agent conçu pour traiter des tâches de langage naturel, comme générer du texte, répondre à des questions ou traduire. Il repose sur le mécanisme d'attention de l'architecture Transformer.
On peut l'imaginer comme un cerveau doté de milliards de nœuds de mémoire : il comprend non seulement les relations locales au sein d'une phrase, mais aussi le contexte global et la logique d'un texte entier.

I. Le RL vs LLM
II. L'évolution historique des LLM
III. Comprendre les LLM à travers le cadre des trois configurations
IV. Etude du LLM pour résoudre le problème SAT

I. Le RL vs LLM

- Un agent **RL** apprend par interaction avec un environnement, en recevant des récompenses; un **LLM**, au contraire, apprend à partir de gigantesques corpus de texte et prédit le prochain token.
- Le RL optimise des actions ; le LLM optimise la modélisation du langage.

II. L'évolution historique des LLM

- Des modèles séquentiels (RNN)
- Puis des modèles à longue mémoire (LSTM/GRU)
- Puis le Transformer (2017), capable de capturer des dépendances longues grâce à l'attention
- L'ère des très grands modèles (GPT, LLaMA, etc.)

Expérience de résolution du problème SAT avec Chatgpt

Exemple de formule SAT :

$(\neg x1 \lor x2) \land (x2 \lor x3) \land (x1 \lor \neg x2 \lor x3)$

Objectif :

Faire résoudre cette formule par :

- ChatGPT (LLM)
- miniSAT Solver

But :

comparer les approches statistiques d'un LLM et l'algorithme exact d'un SAT Solver.

III. Comprendre les LLM avec la méthode en trois configurations

Transformer

Le Transformer est l'architecture centrale des LLM. Grâce au mécanisme d'attention, chaque token peut sélectionner les informations importantes dans la séquence, tandis que les couches empilées permettent d'intégrer le contexte global.

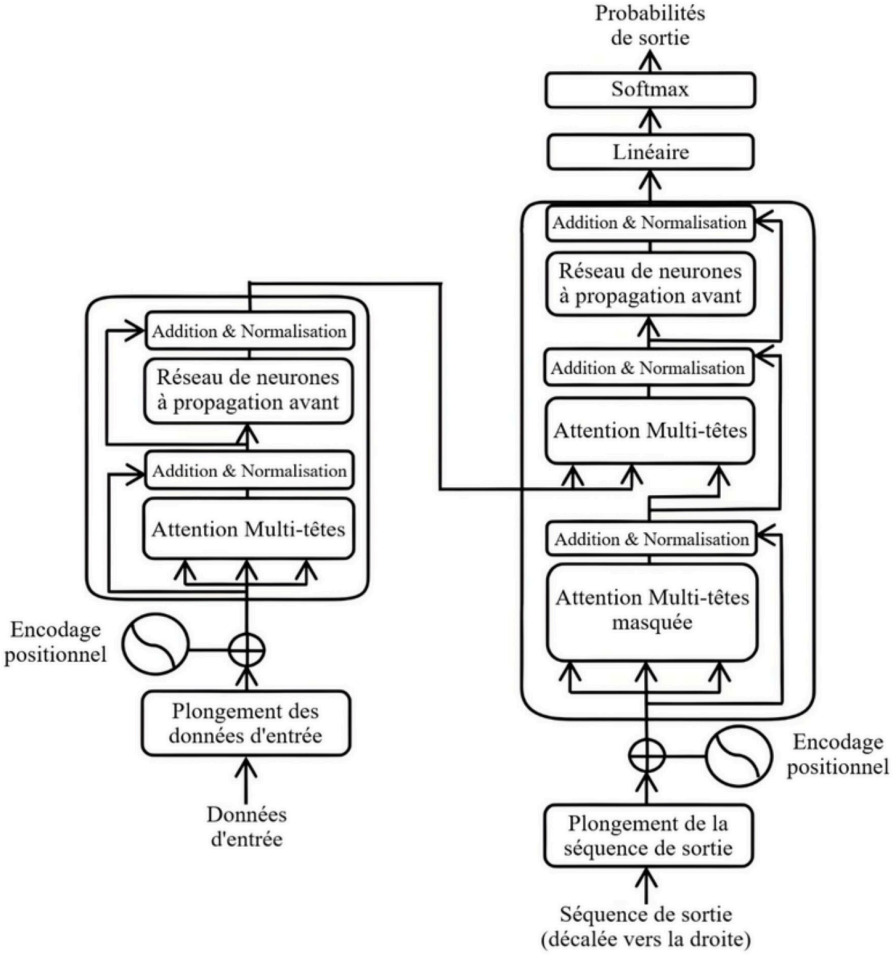

III. Comprendre les LLM avec la méthode en trois configurations

Principes fondamentaux Transformer :

- Entrée séquentielle : le texte est découpé en tokens.
- Embedding : chaque token est représenté par un vecteur de grande dimension, appris par le modèle, qui capture ses propriétés sémantiques et syntaxiques (un point dans l'espace des embeddings).
- Mécanisme d'attention (self-attention) : chaque token peut « examiner et évaluer » les autres tokens pour déterminer lesquels sont pertinents.
- Empilement de couches : le contexte est progressivement fusionné pour construire un sens global.
- Historique d'entraînement (T) : le modèle apprend, à partir de vastes corpus, des modèles linguistiques, des schémas logiques et des régularités du langage.

III. Comprendre les LLM avec la méthode en trois configurations

Exemple 1 :

- **Tokens :** [A, +, C]
- **Version numérique :** [1, +, 2]
- **Embeddings** (représentation vectorielle apprise par le modèle) :

  A = [1, 0]
  B = [0, 1]
  C = [1, 1]

- Supposons que W_Q, W_K, W_V sont des matrices de poids apprises par le modèle :

  W_Q = [[1, 0], [0, 1]]
  W_K = [[1, 0], [0, 1]]
  W_V = [[1, 0], [0, 1]]

Questions :

- Calculer Q/K/V, Attention(Q,K,V)=softmax(dk QKT)V
- Comprendre le sens intuitif de Q/K/V

La méthode en trois étapes (trois configurations)

La méthode en trois configurations:

1. m-configuration : état interne (q)
2. configuration mécanisme (δ)
3. configuration complète (historique (T)

La méthode en trois configurations

1. **m-configuration : état interne (q)**

- **Embedding** : chaque token est représenté par un vecteur de grande dimension, appris par le modèle, qui capture ses propriétés sémantiques et syntaxiques. Ces vecteurs constituent l'état interne (q) de chaque token dans la séquence, reflétant sa représentation interne dans le modèle.

Qu'est-ce qu'un « embedding » (une représentation vectorielle) ?

C'est une méthode qui consiste à projeter des symboles discrets (mots, caractères, tokens) dans un **espace vectoriel continu de grande dimension**, où les vecteurs sont **appris par le modèle** pour capturer les propriétés sémantiques et syntaxiques des tokens.

Par exemple :
« you » → un vecteur de 768 dimensions
« apple » → un vecteur de 768 dimensions
« jogging » → un vecteur de 768 dimensions

Les distances et directions entre ces vecteurs reflètent leurs relations sémantiques :

- les mots similaires ont des vecteurs proches
- les antonymes peuvent avoir des directions opposées
- certaines structures grammaticales peuvent correspondre à des structures géométriques dans l'espace vectoriel

La méthode en trois configurations

2. Mécanisme δ : Q/K/V + Attention + FFN

- Q/K/V : vecteurs dérivés des embeddings, utilisés pour mesurer les relations entre tokens.
- Attention : calcule comment chaque token doit intégrer l'information des autres tokens de la séquence.
- Feed-Forward Network (FFN) : transforme et affine la représentation de chaque token, préparant l'information pour la couche suivante.

Ainsi, à chaque couche, le modèle effectue une « décision locale » (FFN) combinée à une « propagation de l'information » à travers la séquence (Attention).

La méthode en trois configurations

Exemple 1 : le sens intuitive de Q/K/V

"1" :

- Q = Je veux demander : avec quel opérateur dois-je interagir dans le calcul ? (ou je souhaite attirer l'attention de l'opérateur)
- K = Je suis la valeur 1, je peux être opérée
- V = Je suis l'embedding de la valeur 1, utilisée pour le calcul

"+" :

- Q = Je veux demander : quels sont les opérandes gauche et droite ? (j'ai besoin des valeurs numériques pour faire l'addition)
- K = Je suis le symbole « + », je peux fournir l'information sur l'opération
- V = Je peux fournir les caractéristiques de l'opération « + », utilisées pour mettre à jour les représentations

"2" :

- Q = Je veux demander : avec quel opérateur dois-je interagir dans le calcul ?
- K = Je suis la valeur 2, je peux être opérée
- V = Je suis l'embedding de la valeur 2, utilisée pour le calcul

La méthode en trois configurations

- **Calcul et rôle de Q / K / V**

Étant donné une matrice d'embeddings des tokens X (forme : longueur de la séquence × dimension d'embedding) et des matrices de poids W_Q ,W_K ,W_V apprises par le modèle :

$Q=XW_Q$,$K=XW_K$,$V=XW_V$

Autrement dit :
embedding → (transformation linéaire) → Q / K / V

La méthode en trois configurations

- **Calcul de l'attention**

Puis, à partir de Q, K et V :
Attention(Q,K,V)=softmax(dk QKT)V

où dk est la dimension des vecteurs Key.

Explication :

- QKT calcule la similarité entre chaque Query et tous les Keys.
- La softmax normalise ces similarités en **poids d'attention**.
- Ces poids sont appliqués aux Values V pour produire la représentation finale de chaque token.

La méthode en trois configurations

Exemple 1 : Attention (Lecture de la séquence)

- Chaque token regarde les autres tokens avec ses Q/K pour décider **qui est important.**
- Exemple de poids softmax (contribution des tokens pour calculer la nouvelle représentation) :

1 : [0.401 (1), 0.198 (+), 0.401 (2)]
+ : [0.198 (1), 0.401 (+), 0.401 (2)]
2 : [0.254 (1), 0.254 (+), 0.492 (2)]

- **Interprétation :** chaque token intègre l'information pondérée des autres tokens pour enrichir sa représentation.

La méthode en trois configurations

(3) Historique T : l'historique d'entraînement fournit des modèles logiques

- La capacité des LLM provient de l'historique d'entraînement :
  - De grandes quantités de données permettent au modèle d'apprendre des patterns statistiques de langage et de logique.
- Les Q/K/V dans les multiples couches d'attention capturent ces patterns, permettant au modèle de raisonner par analogie.
- L'information historique détermine le comportement émergent : le modèle peut générer des étapes de raisonnement logique lors de l'inférence.

Etude du LLM pour résoudre le problème SAT

(3) Historique T : l'historique d'entraînement fournit des modèles logiques

- La capacité des LLM provient de l'historique d'entraînement :
  - De grandes quantités de données permettent au modèle d'apprendre des patterns statistiques de langage et de logique.
- Les Q/K/V dans les multiples couches d'attention capturent ces patterns, permettant au modèle de raisonner par analogie.
- L'information historique détermine le comportement émergent : le modèle peut générer des étapes de raisonnement logique lors de l'inférence.